



## ۱ ماشین های بردار پشتیبان

$SVM$  یک الگوریتم یادگیری ماشین نظارت شده است که برای وظایف طبقه بندی و رگرسیون استفاده می شود. این فصل چندین مفهوم کلیدی و فرمول بندی های مرتبط با  $SVM$  ها را تشریح می کند. ابتدا مثالی از مسئله بهینه سازی سر کلاس دیدیم. ما داستان ماشین های بردار پشتیبان  $SVMs$  را با صحبت درباره حاشیه ها آغاز می کنیم. این بخش، بینشی درباره حاشیه ها و درباره «اطمینان» پیش بینی های ما خواهد داد. می خواهیم خطی را پیدا کنیم که احتمالاً در آینده قدرت تعمیم<sup>۱</sup> بیشتری خواهد داشت، ذکر این مرحله حاشیه<sup>۲</sup> داریم و هدف ما بیشینه کردن حاشیه یا به نوعی بیشترین حاشیه است. در ادامه شهود ما نسبت به بیشینه سازی حاشیه و شرط خود را نوشتیم. مسئله ی محدب<sup>۳</sup> ما یک جواب دارد که به این نوع مسائل ماشین های بردار پشتیبان حاشیه سخت<sup>۴</sup> گفته می شود.

### فهرست

۱. مفهوم حاشیه

۲.  $SVM$  حاشیه سخت

۳. مسئله دو گانه  $SVM$  حاشیه سخت

۴.  $SVM$  حاشیه نرم

۵. مسئله دو گانه  $SVM$  حاشیه نرم

---

<sup>۱</sup>generalization

<sup>۲</sup>margin

<sup>۳</sup>convex

<sup>۴</sup>hard margin svm

## ۱-۱ مفهوم حاشیه

حاشیه یک صفحه‌ی تصمیم که نمونه‌های دو کلاس قابل تفکیک خطی را جدا می‌کند، کوچکترین فاصله بین مرز تصمیم و هر یک از نمونه‌های آموزشی است. حاشیه بزرگتر معمولاً بهتر به داده‌های دیده نشده تعمیم می‌یابد.

## ۲ فرمولاسیون دوگانه

۵

فرمولاسیون دوگانه ماشین بردار پشتیبان  $SVM$  یک روش جایگزین برای حل مسئله اصلی اولیه است. این فرمولاسیون بینش بیشتری به ابرصفحه<sup>۶</sup> بهینه می‌دهد و استفاده از ترفند کرنل را امکان پذیر می‌کند.

## ۱-۲ تکنیک ضرایب لاگرانژ

فرمولاسیون دوگانه بر اساس تکنیک مولتی پلیر لاگرانژ است، که یک روش بهینه سازی برای حل مشکلات با محدودیت های مساوی یا نامساوی است. این تکنیک شامل معرفی متغیرهای جدید به نام مولتی پلیر لاگرانژ است که مسئله بهینه سازی محدود را به یک مسئله بهینه سازی بدون محدودیت تبدیل می‌کند.

## ۲-۲ مزایای کلیدی

فرمولاسیون دوگانه  $SVM$  چندین مزیت را ارائه می‌دهد، از جمله:

- بینش بیشتری به ابرصفحه بهینه می‌دهد
- استفاده از ترفند کرنل را امکان پذیر می‌کند که برای طبقه بندی غیر خطی استفاده می‌شود
- یک راه حل جایگزین برای مسئله اصلی اولیه را ارائه می‌دهد که در برخی از موقعیت ها مفید است.

## حاشیه سخت

مسئله بهینه‌سازی: هدف یافتن یک صفحه‌ی تصمیم است که حاشیه بین دو کلاس را به حداکثر برساند.

---

<sup>5</sup>Dual formulation of the SVM

<sup>6</sup>hyper-plane

$$\begin{aligned} & \max_{M, \mathbf{w}, w_0} \frac{2M}{\|\mathbf{w}\|} \\ & \text{subject to} \\ & y_i(\mathbf{w}^T \mathbf{x}_i + w_0) \geq M \quad \forall i \end{aligned}$$

تغییر مقیاس پارامترها: این مسئله بهینه‌سازی را با ثابت کردن حاشیه به ۱ ساده می‌کند.

$$\begin{aligned} & \max_{\mathbf{w}', w'_0} \frac{2}{\|\mathbf{w}'\|} \\ & \text{subject to} \\ & y_i(\mathbf{w}'^T \mathbf{x}_i + w'_0) \geq 1 \quad \forall i \end{aligned}$$

فرمول‌بندی معادل:

$$\begin{aligned} & \min_{\mathbf{w}, w_0} \frac{1}{2} \|\mathbf{w}\|^2 \\ & \text{subject to} \\ & y_i(\mathbf{w}^T \mathbf{x}_i + w_0) \geq 1 \quad \forall i \end{aligned}$$

## فرمول‌بندی دوگانه SVM حاشیه سخت

تکنیک ضرایب لاگرانژ: برای مسائل با محدودیت‌های برابری یا نابرابری مفید است.

$$\begin{aligned} & \min_x f(x) \\ & \text{s.t.} \quad g_i(x) \leq 0, \quad i = 1, \dots, m \end{aligned}$$

می‌توانیم تابع لاگرانژی زیر را بسازیم:

$$\mathcal{L}(x, a) = f(x) + \sum_{i=1}^m a_i g_i(x)$$

که در آن  $\mathbf{x}$  متغیر بهینه‌سازی است،  $f(\mathbf{x})$  تابع هدف و  $g_i(\mathbf{x})$  توابع قیود هستند.  
 که در آن  $\alpha = (\alpha_1, \dots, \alpha_m)$  ضرایب لاگرانژ هستند.  
 سپس بهینه‌سازی می‌کنیم:

$$\begin{aligned} \min_{\mathbf{x}} \max_{\alpha \geq 0} \mathcal{L}(\mathbf{x}, \alpha) \\ \max_{\alpha \geq 0} \min_{\mathbf{x}} \mathcal{L}(\mathbf{x}, \alpha) \end{aligned} \quad (۱)$$

در ادامه داریم:

$$\begin{aligned} \text{minimize} \quad & \frac{1}{2} \|w\|^2 \\ \text{subject to} \quad & y^{(i)}(w^T x^{(i)} + w_0) \geq 1 \quad \text{for } i = 1, \dots, N \end{aligned}$$

- $w$ : weight vector
- $w_0$ : bias term
- $x_i$ : input vectors
- $y_i$ : corresponding labels
- $N$ : number of samples

برای ترکیب قیود<sup>۷</sup> در تابع هدف، مولتی‌پلیر لاگرانژ  $\alpha_n \geq 0$  را معرفی می‌کنیم و تابع لاگرانژ را تعریف می‌کنیم:

$$\min_{w, w_0} \max_{a_n \geq 0} \left( \frac{1}{2} \|w\|^2 + \sum_{n=1}^N a_n (1 - y^{(n)}(w^T x^{(n)} + w_0)) \right) \quad (۲)$$

مسئله دوگانه با تعویض ترتیب عملیات مینیمم و ماکسیمم به دست می‌آید که معادل است با:

$$\max_{a_n \geq 0} \min_{w, w_0} \left( \frac{1}{2} \|w\|^2 + \sum_{n=1}^N a_n (1 - y^{(n)}(w^T x^{(n)} + w_0)) \right) \quad (۳)$$

---

<sup>۷</sup>constraint

تابع لاگرانژ تابع هدف اصلی را با توابع قیود ترکیب می کند که توسط مولتی پلیر لاگرانژ وزن می شوند.

$$\max_{\alpha_n \geq 0} \min_{w, w_0} \mathcal{L}(w, w_0, \alpha) \quad (۴)$$

$$\mathcal{L}(w, w_0, \alpha) = \frac{1}{2} \|w\|^2 + \sum_{n=1}^N \alpha_n (1 - y^{(n)}(w^T x^{(n)} + w_0)) \quad (۵)$$

$$\nabla_w \mathcal{L}(w, w_0, \alpha) = 0 \Rightarrow w = \sum_{n=1}^N \alpha_n y^{(n)} x^{(n)} \quad (۶)$$

$$\frac{\partial}{\partial w_0} \mathcal{L}(w, w_0, \alpha) = 0 \Rightarrow \sum_{n=1}^N \alpha_n y^{(n)} = 0 \quad (۷)$$

این مسئله معادل مسئله اصلی است. مسئله ماکسیمم داخلی برای یافتن مولتی پلیر لاگرانژ بهینه است که محدودیت ها را برآورده می کند، در حالی که مسئله مینیمم خارجی برای یافتن مقادیر بهینه  $w_0$  و  $w$  است که تابع لاگرانژ را به حداقل می رسانند.

$$w = \sum_{n=1}^N a_n y^{(n)} x^{(n)} \sum_{n=1}^N a_n y^{(n)} = 0 \quad (۸)$$

$$\mathcal{L}(w, w_0, \alpha) = \frac{1}{2} w^T w + \sum_{n=1}^N \alpha_n (1 - y^{(n)}(w^T x^{(n)} + w_0)) \quad (۹)$$

$$\mathcal{L}(\alpha) = \sum_{n=1}^N \alpha_n - \frac{1}{2} \sum_{m=1}^N \sum_{n=1}^N \alpha_n \alpha_m y^{(m)} y^{(n)} x^{(m)T} x^{(n)} \quad (۱۰)$$

$$\begin{aligned}
& \text{Maximize with respect to } \alpha \quad \sum_{n=1}^N \alpha_n - \frac{1}{2} \sum_{n=1}^N \sum_{m=1}^N \alpha_n \alpha_m y^{(n)} y^{(m)} x^{(n)T} x^{(m)} \\
& \text{subject to} \quad \alpha_n \geq 0 \quad \text{for } n = 1, \dots, N \\
& \quad \sum_{n=1}^N \alpha_n y^{(n)} = 0
\end{aligned}$$

این معادلات بخشی از فرمول‌بندی برای مسئله بهینه‌سازی ماشین بردار پشتیبان (SVM) هستند. معادله اول بردار وزن ( $w$ ) را بر حسب ضرایب‌های لاگرانژ ( $\alpha_n$ )، برچسب‌ها ( $y^{(n)}$ ) و بردارهای ورودی ( $x^{(n)}$ ) تعریف می‌کند. معادله دوم شروط را نشان می‌دهد که مجموع حاصل ضرب مولتی‌پلیرهای لاگرانژ و برچسب‌ها باید برابر با صفر باشد. معادله سوم لاگرانژ ( $L$ ) است که باید نسبت به ضرایب‌های لاگرانژ ( $\alpha$ ) حداکثر شود، مشروط به قیدهایی که در آخرین معادله داده شده است.

$$\begin{aligned}
& \max_{\alpha} \left( \sum_{n=1}^N \alpha_n - \frac{1}{2} \sum_{n=1}^N \sum_{m=1}^N \alpha_n \alpha_m y^{(n)} y^{(m)} (x^{(n)})^T x^{(m)} \right) \\
& \text{subject to } \sum_{n=1}^N \alpha_n y^{(n)} = 0, \\
& \alpha_n \geq 0, \quad n = 1, \dots, N
\end{aligned} \tag{11}$$

مسئله دوگانه یک مسئله  $QP$  محدب است که می‌تواند با استفاده از الگوریتم‌های بهینه‌سازی مختلف به‌طور موثر حل شود.

: *Quadratic programming*

$$\begin{aligned}
& \min_{\alpha} \frac{1}{2} \alpha^T \begin{bmatrix} y^{(1)} y^{(1)} x^{(1)T} x^{(1)} & \dots & y^{(1)} y^{(N)} x^{(1)T} x^{(N)} \\ \vdots & \ddots & \vdots \\ y^{(N)} y^{(1)} x^{(N)T} x^{(1)} & \dots & y^{(N)} y^{(N)} x^{(N)T} x^{(N)} \end{bmatrix} \alpha + (-1)^T \alpha \\
& \text{s.t.} \quad -\alpha \leq 0, \quad y^T \alpha = 0
\end{aligned}$$

$$w = \sum_{n=1}^N \alpha_n y^{(n)} x^{(n)}$$

• شروط مهمی که باید برقرار باشد  $[w^*, w_0^*, \alpha^*]$ :


$$\alpha_n^* \geq 0, \quad n = 1, \dots, N \quad ۱.$$

$$y^{(n)}(w^{*T}x^{(n)} + w_0^*) \geq 1, \quad n = 1, \dots, N \quad ۲.$$

$$\alpha_n^*(1 - y^{(n)}(w^{*T}x^{(n)} + w_0^*)) = 0, \quad n = 1, \dots, N \quad ۳.$$

نقاط با  $\alpha \neq 0$  هستند که حتماً روی خط می افتند.

$\begin{aligned} &\min_x f(x) \\ &\text{s.t. } g_i(x) \leq 0 \quad i = 1, \dots, m \end{aligned}$	$\mathcal{L}(x, \alpha) = f(x) + \sum \alpha_i g_i(x)$ <p>In general, the optimal <math>x^*, \alpha^*</math> satisfies KKT conditions:</p>	$\begin{aligned} \alpha_i^* &\geq 0 \quad i = 1, \dots, m \\ g_i(x^*) &\leq 0 \quad i = 1, \dots, m \\ \alpha_i^* g_i(x^*) &= 0 \quad i = 1, \dots, m \end{aligned}$
---	--	--



## ۳-۲ قیود غیرفعال:

این قیودی است که بر حل بهینه مسئله تأثیر نمی گذارد. این قیود در سمت چپ اسلاید شما نمایش داده شده است. شرط برای قیود غیرفعال این است که در نقطه بهینه  $(x^*)$  برابر با صفر نباشد، که به صورت ریاضی به صورت  $g_i(x) \neq 0$  نمایش داده می شود. در نمودار، نقطه بهینه  $(x^*)$  در داخل منطقه مجاز اما نه

بر روی مرز تعریف شده توسط قیود قرار دارد، و ضریب لاگرانژ مربوطه ( $\alpha$ ) برابر با صفر است.

$$y^{(n)}(w^T x^{(n)} + w_0) > 1$$

$$\Rightarrow \alpha_n = 0, x^{(n)}$$


بردار پشتیبان نیست .

## ۴-۲ قیود فعال:

این قیودی است که بر حل بهینه مسئله تأثیر مستقیم دارد. این قیود در سمت راست اسلاید شما نمایش داده شده است. برای قیود فعال، شرط این است که در نقطه بهینه ( $x^*$ ) برابر با صفر باشد، که به صورت ریاضی به صورت ( $g_i(x) = 0$ ) نمایش داده می‌شود. اینجا، نقطه بهینه ( $x^*$ ) بر روی مرز منطقه مجاز قرار دارد، که لبه تعریف شده توسط قیود است.

$$y^{(n)}(w^T x^{(n)} + w_0) = 1$$

نقاطی که روی مارجین می افتند برای ما قیود فعال هستند که می توانند جای بهینه را عوض کنند .  
(همانطور که در فرمول مشخص است )



لاگرانژ مربوطه برای آن بزرگتر از صفر است. این بدان معنی است که یک بردار پشتیبان یک نقطه داده  $x^{(n)}$  است که ضریب  $(SVs) = x^{(n)} | \alpha_n > 0$

جهت ابر صفحه (مرز تصمیم) را می توان تنها بر اساس بردارهای پشتیبانی تعیین کرد. این به این دلیل



است که بردارهای پشتیبان، نقاط داده ای هستند که نزدیک ترین نقطه به ابر صفحه قرار دارند و بیشترین تأثیر را در جهت آن دارند.

جهت ابر صفحه  $W$  را می توان با استفاده از فرمول زیر محاسبه کرد:

$$w = \sum_{\alpha_n > 0} \alpha_n y^{(n)} x^{(n)}$$

پس از حل مسئله برنامه نویسی درجه دوم ( $\square\square$ ) برای یافتن ضرایب لاگرانژ، می توانیم بردار وزن را با استفاده از فرمول زیر پیدا کنیم:

$$w = \sum_{n=1}^N \alpha_n y^{(n)} x^{(n)}$$

هر یک از نمونه هایی که دارای  $\alpha_s > 0$  هستند در حاشیه قرار می گیرند ، به این معنی که آنها به ابر صفحه نزدیک ترین هستند. بنابراین، ما می توانیم از هر یک از این  $SV$  ها برای حل  $w_0$  استفاده کنیم.

$$y(s)(\mathbf{w}^T \mathbf{x}(s) + w_0) = 1$$

$$\Rightarrow w_0 = y^{(s)} - \mathbf{w}^T \mathbf{x}^{(s)}$$

## ۲-۵ طبقه بندی نمونه های جدید

هنگام طبقه بندی یک نمونه جدید،  $SVM$  با حاشیه سخت از فرمول زیر استفاده می کند:

$$\hat{y} = \text{sign}(w_0 + w^T x)$$

این نشان دهنده تابع تصمیم گیری یک  $SVM$  است. برچسب پیش بینی شده ( $\hat{y}$ ) را محاسبه می کند.

$$\hat{y} = \text{sign} \left( w_0 + \left( \sum_{\alpha_n > 0} \alpha_n y^{(n)} x^{(n)} \right)^T x \right)$$

تابع تصمیم گیری به شکل گسترش یافته صورت بالا است ، مجموع بر روی همه بردارهای پشتیبان (نمونه هایی که  $\alpha_n > 0$ ) اجرا می شود.

$$\hat{y} = \text{sign} \left( y^{(s)} - w_0 - \sum_{\alpha_n > 0} \alpha_n y^{(n)} (x^{(n)})^T x^{(s)} \right) + \sum_{\alpha_n > 0} \alpha_n y^{(n)} (x^{(n)})^T x$$

با جابجایی و کم و زیاد کردن واریانس کرنل گوشتی، مرزهای ما بیشتر و بیشتر جابجا می شوند و اورفیت ایجاد می کنند و دور هر دیتای ترین جمع و غیر خطی می شوند.

$$\max_{\alpha} \left( \sum_{n=1}^N \alpha_n - \frac{1}{2} \sum_{n=1}^N \sum_{m=1}^N \alpha_n \alpha_m y^{(n)} y^{(m)} (x^{(n)})^T x^{(m)} \right)$$

Subject to the constraints:

$$\sum_{n=1}^N \alpha_n y^{(n)} = 0$$

and

$$\alpha_n \geq 0 \quad \text{for } n = 1, \dots, N$$

### ۳ ماشین بردار پشتیبان در مسائل خطی تفکیک ناپذیر (*Soft-margin SVM*)

در بسیاری از مسائل دنیای واقعی، داده‌ها نمی‌توانند به طور کامل توسط یک مرز خطی جدا شوند. تقریباً جدایی خطی به داده‌هایی اشاره دارد که تقریباً می‌توانند توسط یک مرز خطی جدا شوند اما ممکن است چند نمونه به اشتباه طبقه‌بندی شده یا درون حاشیه قرار گیرند. گاهی داده‌ها انقدر تمیز نیستند و ممکن است داده‌ها با آنکه به صورت خطی جدایی‌پذیر هستند، ولیدر هم رفته اند و کاملاً تفکیک شده نباشند. برای همچنین حالاتی از *Soft-margin SVM* استفاده می‌کنیم.

#### ۱-۳ مفهوم حاشیه نرم

هدف: حداکثر کردن حاشیه در حالی که اجازه می‌دهد برخی نقاط در طرف اشتباه حاشیه یا حتی اشتباه طبقه‌بندی شوند. متغیرهای شل ( $\xi_i$ ) برای هر نقطه داده برای اندازه‌گیری درجه اشتباه طبقه‌بندی یا نقض حاشیه معرفی شده‌اند.

#### ۲-۳ کمینه کردن تعداد نقاط طبقه‌بندی شده اشتباه:

ایده‌آل این است که یک *SVM* تمام نقاط آموزشی را به طور کامل طبقه‌بندی کند. با این حال، این همیشه ممکن نیست، به ویژه با داده‌های پرسر و صدا. هدف کمینه کردن این طبقه‌بندی‌های اشتباه است. در این حالت ما اجازه می‌دهیم برخی از داده‌ها در آموزش دچار خطا بشوند. *SVM* با حاشیه نرم یک متغیر اسلک ( $\xi$ ) (*slack variable*) را برای هر نقطه داده معرفی می‌کند تا

اجازه دهد برخی از طبقه‌بندی‌های اشتباه وجود داشته باشند. هدف یافتن تعادل بین حداکثر کردن حاشیه (فاصله بین صفحه جداکننده و نزدیک‌ترین نقاط داده از هر کلاس) و کمینه کردن مجموع این متغیرهای اسلک است که نمایانگر جریمه کلی برای هر گونه طبقه‌بندی اشتباه است.

$$\min_{w,b,\xi} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i$$

Subject to the constraints:



$$y^{(n)}(w^T x^{(n)} + w_0) \geq 1 - \xi_i \quad \text{and} \quad \xi_i \geq 0 \quad n = 1, \dots, N$$

## Error measure

► Margin violation amount  $\xi_n$  ( $\xi_n \geq 0$ ):

►  $y^{(n)}(w^T x^{(n)} + w_0) \geq 1 - \xi_n$

► Total violation:  $\sum_{n=1}^N \xi_n$



$\xi_n$ : **slack variables**

$0 < \xi_n < 1$ : if  $x^{(n)}$  is correctly classified but inside margin

$\xi_n > 1$ : if  $x^{(n)}$  is misclassified

دو دسته قید داریم یکی مانند قبل و دیگری روی اسلک ها .

لاگرانژ روشی برای یافتن ماکزیمم و مینیمم های محلی یک تابع تحت قیود تساوی است، یعنی حداکثر

$f(x, y)$  تحت قید  $g(x, y) = c$ . توابع  $f(\cdot)$  و  $g(\cdot)$  باید دارای مشتقات جزئی اول پیوسته باشند.

لاگرانژیان، نمایش داده شده با  $\mathcal{L}(x, y, \lambda)$ ، با ترکیب تابع هدف  $f(x, y)$  و تابع قید  $g(x, y)$  به همراه ضریب لاگرانژ  $\lambda$  به دست می آید که می تواند مثبت یا منفی باشد. به طور ریاضی،  $\mathcal{L}(x, y, \lambda) = f(x, y) + \lambda(g(x, y) - c)$ .

اگر  $f(x_0, y_0)$  ماکزیمم تابع  $f(x, y)$  برای مسئله اصلی تحت قید باشد، سپس وجود دارد  $\lambda$  به گونه ای که  $(x_0, y_0, \lambda_0)$  یک نقطه ایستایی برای تابع لاگرانژ است (بنابراین  $\partial \mathcal{L} / \partial x = \partial \mathcal{L} / \partial y = 0$ ). تابع لاگرانژین را تشکیل می دهیم :

$$\mathcal{L}(w, w_0, \xi, \alpha, \beta) = \frac{1}{2} \|w\|^2 + C \sum_{n=1}^N \bar{\xi}_n + \sum_{n=1}^N \alpha_n (1 - \xi_n - y^{(n)}(w^T x^{(n)} + w_0)) - \sum_{n=1}^N \beta_n \xi_n$$

$$\begin{aligned} \max_{\alpha} \quad & \sum_{n=1}^N \alpha_n - \frac{1}{2} \sum_{n=1}^N \sum_{m=1}^N \alpha_n \alpha_m y^{(n)} y^{(m)} (x^{(n)})^T x^{(m)} \\ \text{s.t.} \quad & 0 \leq \alpha_n \leq C, \quad n = 1, \dots, N \\ & 0 = \sum_{n=1}^N y^{(n)} \alpha_n \end{aligned} \quad (12)$$

پس از حل مسئله درجه دوم بالا،  $w$  به صورت زیر پیدا می شود:

$$w = \sum_{n=1}^N \alpha_n y^{(n)} x^{(n)}$$

### شرایط کاروش-کان-تاکر (KKT)

شرایط KKT مجموعه ای از شرایط ریاضی هستند که به ما کمک می کنند تا تعیین کنیم آیا یک راه حل برای یک مسئله بهینه سازی، بهینه است یا خیر. این شرایط ضروری هستند، به این معنا که اگر یک راه حل شرایط KKT را برآورده کند، آنگاه می تواند یک راه حل بهینه باشد، اما ممکن است تنها راه حل بهینه نباشد.

شرایط KKT به مسائل بهینه سازی که دارای یک تابع هدف و مجموعه ای از محدودیت ها هستند اعمال می شوند. تابع هدف، تابعی است که می خواهیم آن را کمینه یا بیشینه کنیم، و محدودیت ها شرایطی هستند که راه حل ما باید آن ها را برآورده کند.

در زمینه ماشین های بردار پشتیبان (SVM)، شرایط KKT برای یافتن مقادیر بهینه وزن ها، بایاس، و ضرایب لاگرانژ که مرز تصمیم گیری SVM را تعریف می کنند، استفاده می شود.

شرایط  $KKT$  برای مسئله دوگان  $SVM$  شامل موارد زیر است:

- عدم منفی بودن ضرایب لاگرانژ:  $\alpha_i \geq 0$  برای همه  $i$ .
- شرط حاشیه:  $y^{(n)}(w^{*T}x^{(n)} + w_0^*) \geq 1 - \xi_n^*$  برای همه  $n$ . این شرط اطمینان می‌دهد که نقاط داده روی حاشیه دارای حاشیه تابعی حداقل ۱ هستند.
- مکمل اسلک:  $\alpha_i^*(1 - y^{(n)}(w^{*T}x^{(n)} + w_0^*) - \xi_n^*) = 0$  برای همه  $n$ . این شرط اطمینان می‌دهد که یا ضریب لاگرانژ  $\alpha_i^*$  صفر است یا محدودیت  $y^{(n)}(w^{*T}x^{(n)} + w_0^*) \geq 1 - \xi_n^*$  به صورت مساوی برآورده شده است.
- عدم منفی بودن متغیرهای اسلک:  $\xi_n \geq 0$  برای همه  $n$ . متغیرهای اسلک میزان مجاز نقض محدودیت حاشیه را اندازه‌گیری می‌کنند.
- عدم وجود شکاف دوگان:  $\xi_n \beta_n = 0$  برای همه  $n$ . این شرط اطمینان می‌دهد که شکاف دوگان بین توابع هدف اولیه و دوگان مسئله بهینه‌سازی  $SVM$  وجود ندارد.

$SVM$  با حاشیه نرم: بردارهای پشتیبان

- بردارهای پشتیبان نقاط داده آموزشی هستند که مرز تصمیم‌گیری (فراصفحه)  $SVM$  را تعریف می‌کنند.
- دو نوع بردار پشتیبان وجود دارد که با مقدار ضریب لاگرانژ  $\alpha_n$  مشخص می‌شوند:

۱ بردارهای پشتیبان حاشیه: این‌ها نقاط داده‌ای هستند که دقیقاً روی حاشیه در اطراف مرز تصمیم‌گیری قرار دارند. این‌ها دارای  $0 < \alpha_n < C$  هستند.

✳ معادله  $y^{(n)}(w^T x^{(n)} + w_0) = 1$  برای این بردارهای پشتیبان برقرار است، که به این معناست که این‌ها به درستی طبقه‌بندی شده‌اند و روی حاشیه قرار دارند.

✳ آن‌ها با  $(\xi_n = 0)$  نمایش داده می‌شوند زیرا متغیر اسلک  $\xi_n$  برای این نقاط صفر است.

۲ بردارهای پشتیبان غیر حاشیه  $non - marginsupportvector$ : این‌ها نقاط داده‌ای هستند که در طرف اشتباه حاشیه یا داخل حاشیه قرار دارند. این‌ها دارای  $\alpha_n = C$  هستند.

✳ معادله  $y^{(n)}(w^T x^{(n)} + w_0) < 1$  برای این بردارهای پشتیبان برقرار است، که به این معناست که این‌ها یا به اشتباه طبقه‌بندی شده‌اند یا به درستی طبقه‌بندی شده‌اند اما در داخل حاشیه قرار دارند.

✱ آن‌ها با  $(\xi_n > 0)$  نمایش داده می‌شوند زیرا متغیر اسلک  $\xi_n$  برای این نقاط بزرگتر از صفر است.


✱ معادله  $C - \alpha_n - \beta_n = 0$  نیز برای این بردارهای پشتیبان صدق می‌کند.

به طور کلی، بردارهای پشتیبان حاشیه عرض حاشیه را تعریف می‌کنند، در حالی که بردارهای پشتیبان غیر حاشیه اجازه می‌دهند که برخی از طبقه‌بندی‌ها اشتباه باشد اما بر اساس پارامتر هزینه  $C$  جریمه می‌شوند. پارامتر هزینه  $C$  تعادلی بین حداکثرسازی حاشیه و اجازه دادن به برخی اشتباهات طبقه‌بندی را کنترل می‌کند.

تصاویر نمونه‌ای از یک ماشین بردار پشتیبان ( $SVM$ ) را با استفاده از هسته گاوسی ( $RBF$ ) برای طبقه‌بندی نشان می‌دهد که مرز تصمیم و نواحی حاشیه را نشان می‌دهد.

### SVM Gaussian kernel: Example

$$\sigma = 1.0 \quad C = \infty$$




50

This example has been adopted from Zisserman's slides

## SVM Gaussian kernel: Example


$$\sigma = 1.0 \quad C = 100$$



This example has been adopted from Zisserman's slides

## SVM Gaussian kernel: Example


$$\sigma = 1.0 \quad C = 10$$



This example has been adopted from Zisserman's slides

## SVM Gaussian kernel: Example

$$\sigma = 1.0 \quad C = \infty$$




53

This example has been adopted from Zisserman's slides

## SVM Gaussian kernel: Example

$$\sigma = 0.25 \quad C = \infty$$




54

This example has been adopted from Zisserman's slides



## SVM Gaussian kernel: Example

$$\sigma = 0.1 \quad C = \infty$$



55

This example has been adopted from Zisserman's slides